INTELIGÊNCIA ARTIFICIAL

Aprendizado Descritivo
Clustering

Marcos de Souza
mso2@cesar.school

C.E.S.A.R school

Marcos de Souza

Bacharel em Ciência da Computação (UniFG) - 2014

Mestre em Ciência da Computação (UFPE) - 2018

Doutorando em Ciência da computação (UFPE) - 2020

SE @ CESAR - 2017
DS @ CESAR - 2019

Professor @ CESAR School - 2022

Website: marcosd3souza.github.io

Github: https://github.com/marcosd3souza

Lattes: http://lattes.cnpq.br/6137784444858483

Agenda

Dia 1

- Representação dos dados
  - Imagens
  - Texto
  - Áudio
  - Séries temporais
- Medidas de distância
  - Euclidiana
  - Cossenos
  - Hamming

Dia 2

- Métodos de Clustering
  - K-Means
  - Hierarchical
  - redes SOM
  - Spectral
  - Louvain (graph)
- Exercícios

Dia 3

Avaliação de Clusters

- Silhueta
- Hopkins test
- Entropia e NMI

Exercícios

Dia 4

Seleção de Features

- métodos supervisionados
  - correlação, fisher score, chi quadrado

Extração de Features

- PCA, NMF, AutoEncoders

Dia 5

- métodos não supervisionados de FS
  - filter
  - wrapper
  - embedded

Dia 6

- Introdução ao Deep Clustering

Exercícios

1

Representação dos Dados

- Como representar imagens, textos, áudios e material genético através dos dados ?
- Quais tratamentos são necessários a esses dados ?

Representação dos Dados

- Geralmente os algoritmos de aprendizagem de máquina lidam com uma estrutura matricial dos dados (chamaremos essa matriz de **dataset**)
- Estruturas relacionais são convertidas para a geração de uma única tabela contendo todos os dados
- No **dataset** denominamos as linhas como **exemplos**, **instâncias** ou **objetos** e nas colunas como **atributos** ou **features**
- Nessa disciplina utilizaremos todos os **exemplos** do dataset a fim de identificar **padrões**

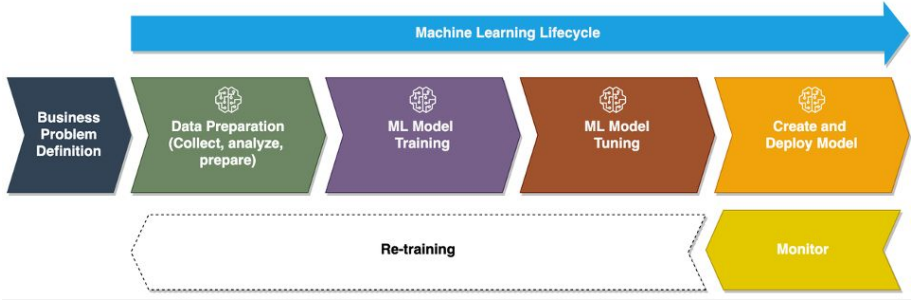

Representação dos Dados - Imagens

- Imagens coloridas são inicialmente representadas por 3 canais (RGB)
- A imagem em cada camada é representada por um conjunto de pixels onde seu valor varia de 0 a 255

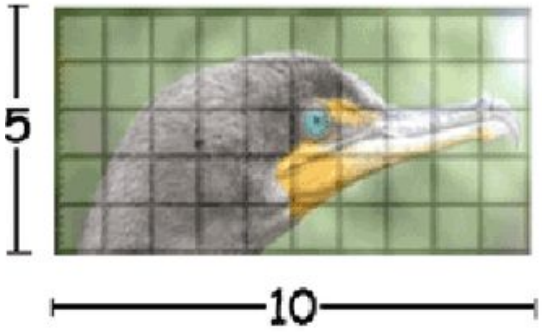

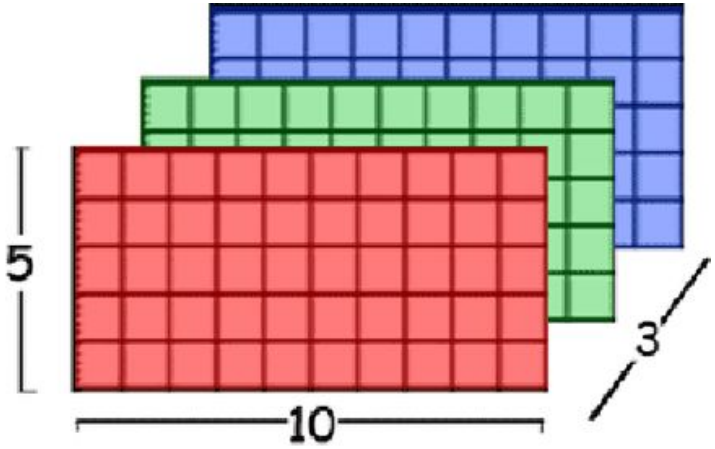

Representação dos Dados - Imagens

- Sem realizar muitas alterações na imagem original podemos reduzir a um único canal em escala de cinza

$$Y = 0.2126R + 0.7152G + 0.0722B$$

Representação dos Dados - Imagens

- Uma vez convertidas as imagens em escala de cinza conseguimos construir nosso dataset, sendo:
  - cada imagem um exemplo (linha) e cada pixel um atributo (coluna)
- Em algumas áreas as imagens tendem a possuir alta resolução (ex: imagens médicas)

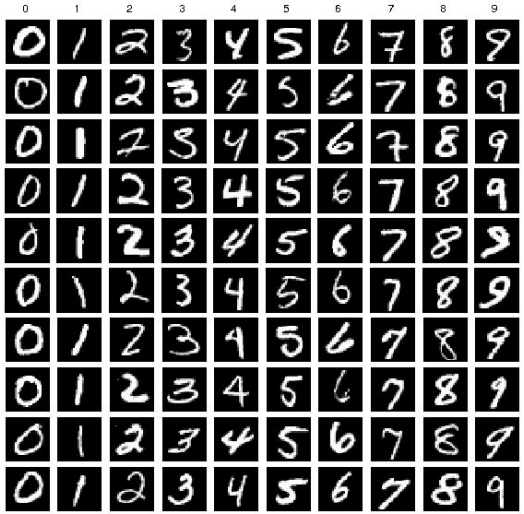

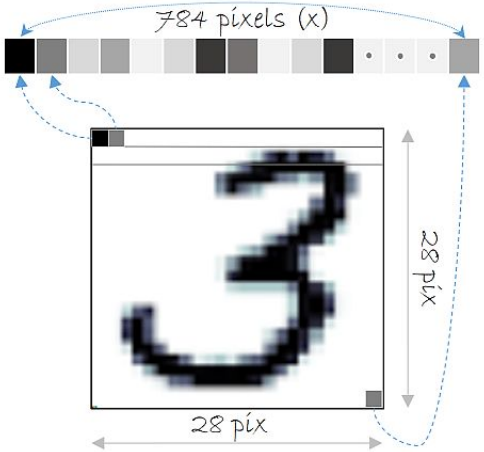

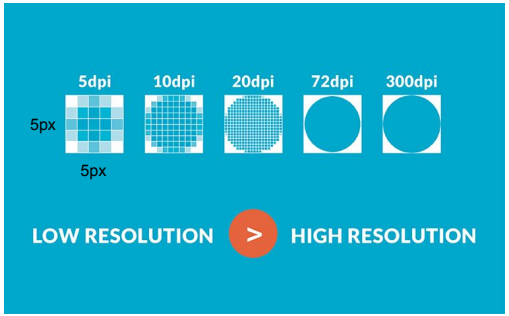

Representação dos Dados - Texto

- Os textos curtos são representados pelos termos únicos
- O pré-processamento se dá pela remoção de pontuação e stopwords (artigos, conectores, etc)

1

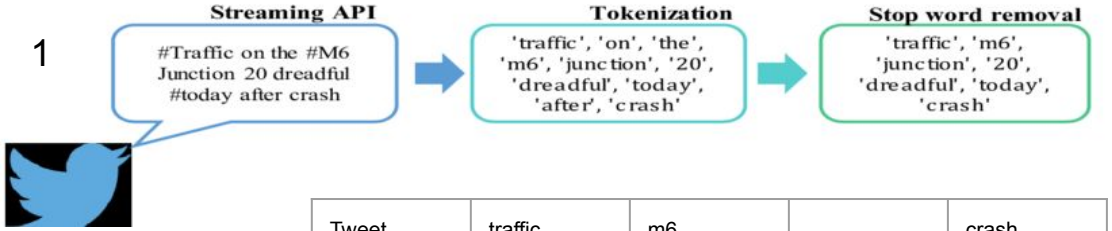

Tweet	traffic	m6		crash
1	1	1		1
2	1	0	…	0
…				
N				

Representação dos Dados - Texto

- Os datasets de texto possuem naturalmente uma alta dimensionalidade
- Um tratamento imediato seria remover os termos (colunas) com baixa frequência (ex = 1)

	text
0	Eddard Stark is a king in the north.
1	A king but one king : kings are everywhere.
2	Hodor was different : he was not a king .
3	But the North could not change without him.

	king	was	the	not	But	him	one	north	kings	is	in	he	Eddard	everywhere	different	could	change	but	are	Stark	North	Hodor	without
0	1	0	1	0	0	0	0	1	0	1	1	0	1	0	0	0	0	0	0	1	0	0	0
1	2	0	0	0	0	0	1	0	1	0	0	0	0	1	0	0	0	1	1	0	0	0	0
2	1	2	0	1	0	0	0	0	0	0	0	1	0	0	1	0	0	0	0	0	0	1	0
3	0	0	1	1	1	1	0	0	0	0	0	0	0	0	0	1	1	0	0	0	1	0	1
	4	3	2	2	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

Representação dos Dados - Áudio

- Antes da extração das features é preciso extrair os trechos de voz

Representação dos Dados - Áudio

- O áudio é inicialmente dividido em frames e em seguida as features são extraídas
- São utilizadas diversas técnicas tais como detecção de timbre, frequência, energia, etc

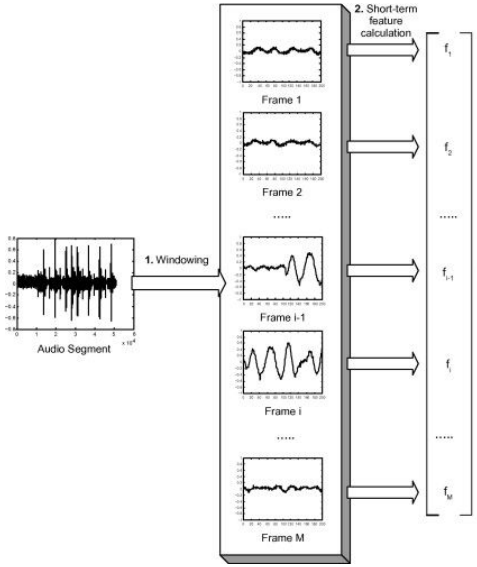

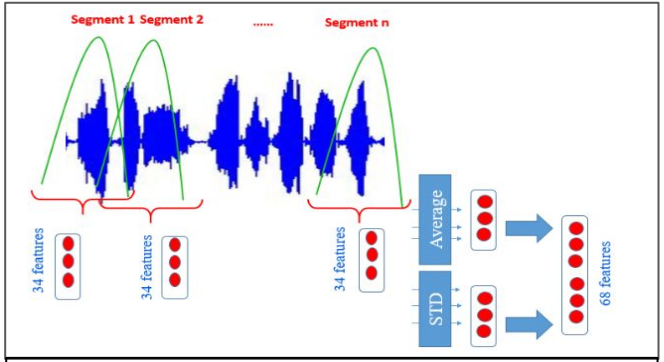

Al-Azani, Sadam & El-Alfy, El-Sayed. (2019). **Multimodal Age-Group Recognition for Opinion Video Logs using Ensemble of Neural Networks**. International Journal of Advanced Computer Science and Applications. 10. 10.14569/IJACSA.2019.0100445.

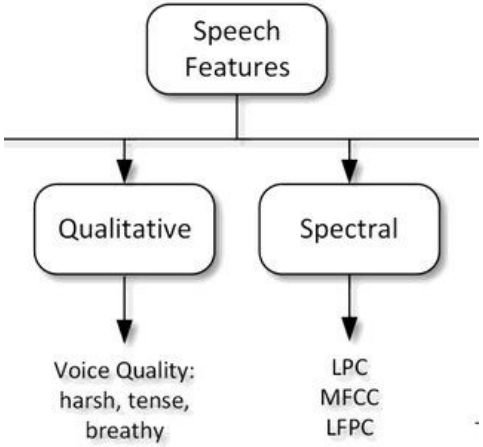

Representação dos Dados - Microarray

Através da análise de microarray (dados genéticos) buscamos identificar os genes com maior expressão para uma determinada doença/tumor/estudo.

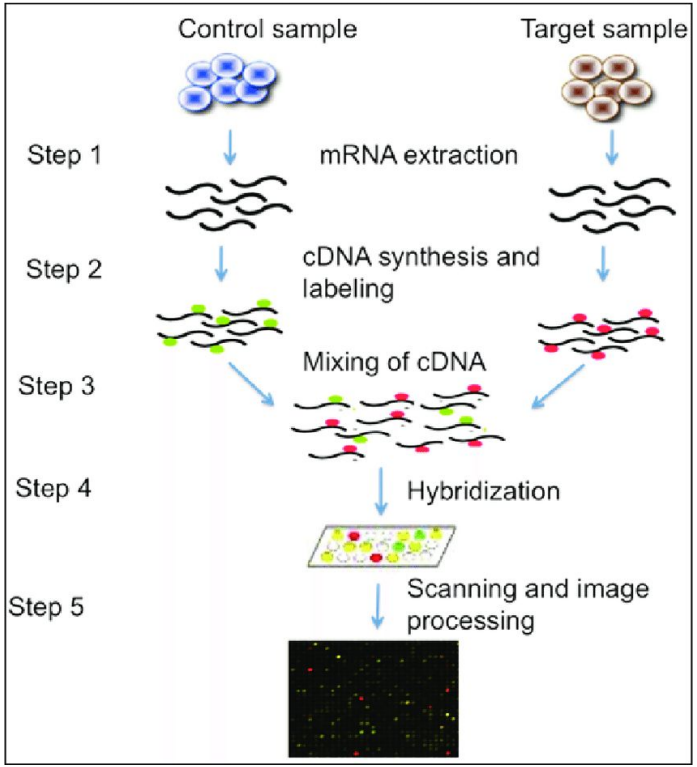

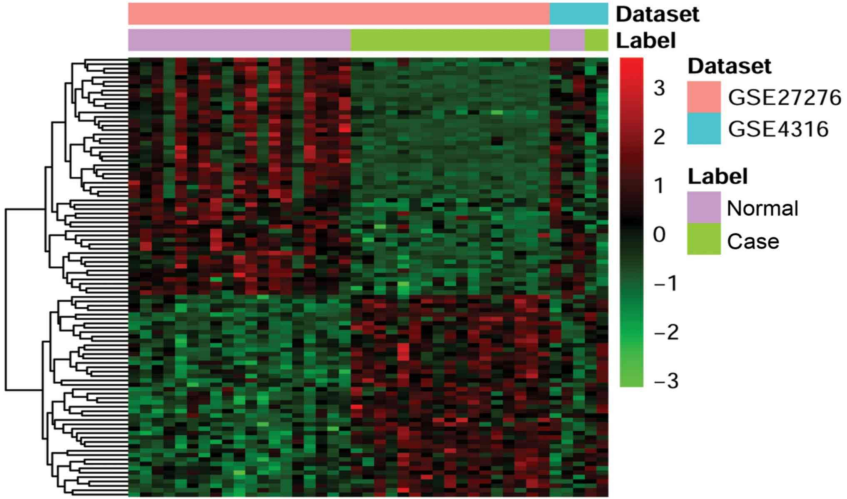

FENG, Jie; XU, Jing. Identification of pathogenic genes and transcription factors in glaucoma. **Molecular medicine reports**, v. 20, n. 1, p. 216-224, 2019.

Representação dos Dados - Séries Temporais

É comum encontrarmos séries temporais no dia a dia, em área como:

- ações no mercado financeiro
- consumo de um recurso computacional (CPU ou memória) ao longo do tempo
- acompanhamento de vendas ao longo do tempo

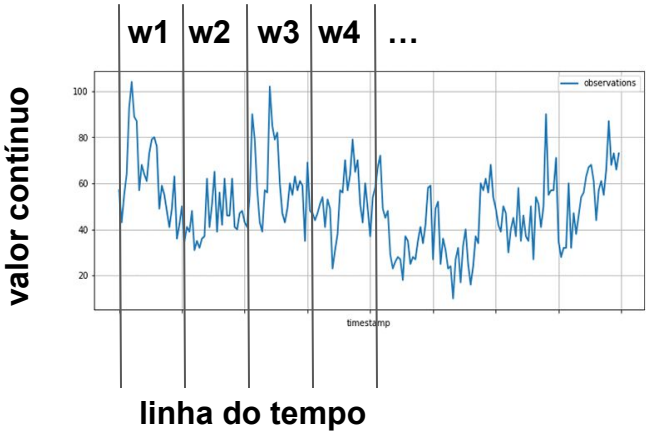

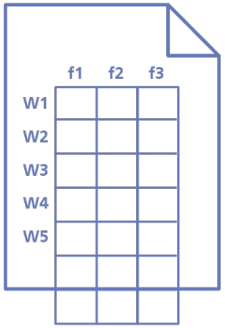

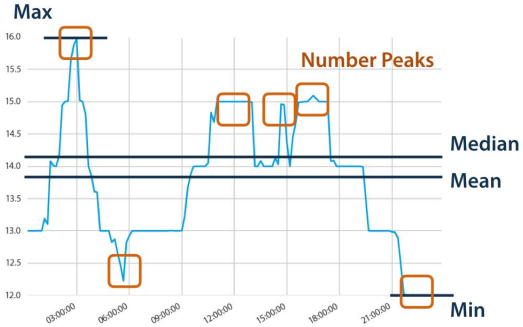

Repositórios

Gene Expression Omnibus

kaggle

UCI Machine Learning Repository

Google Dataset Search Beta

Solar photovoltaics deployment statistics

Solar photovoltaics deployment statistics

Try: boston education data or weather site:noaa.gov

Links de Suporte

https://machinelearningmastery.com/machine-learning-in-python-step-by-step/

- Cluster Tendency
  - Hopkins Test Kaggle
  - Hopkins Test Paper
- Scikit
  - Classificação
  - Regressão Linear
  - Clusterização
    - KMeans
  - Avaliação de Modelos (Métricas)
    - Validação cruzada
- Tutorial
  - Pandas
  - Numpy
  - MatplotLib 1
  - MatplotLib 2
  - Seaborn

2

Medidas de Distância

Normalmente padrões são identificados a partir de uma **similaridade** entre os **exemplos**

Aprendizado Não-Supervisionado (Descritivo)

Na literatura existem diversas opções para se calcular a distância entre dois objetos

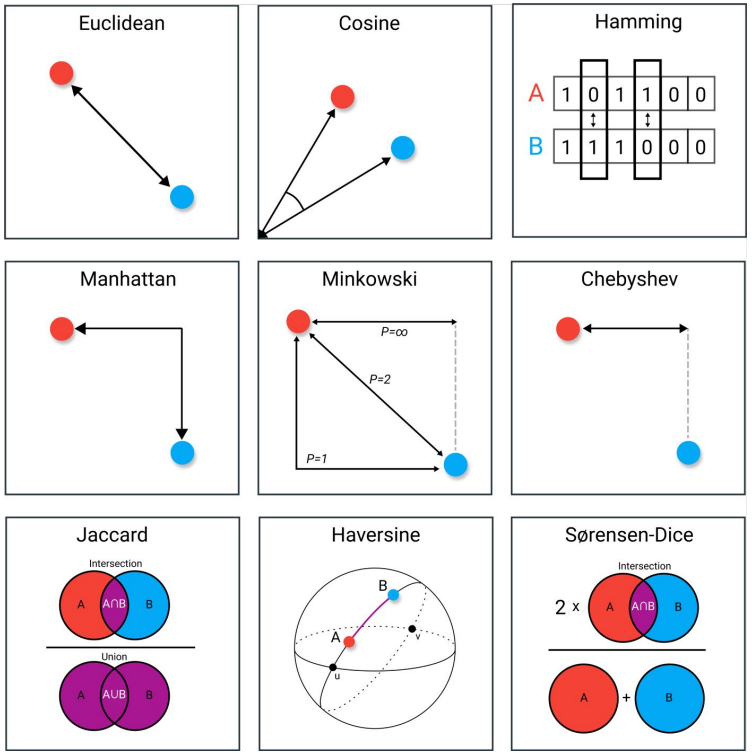

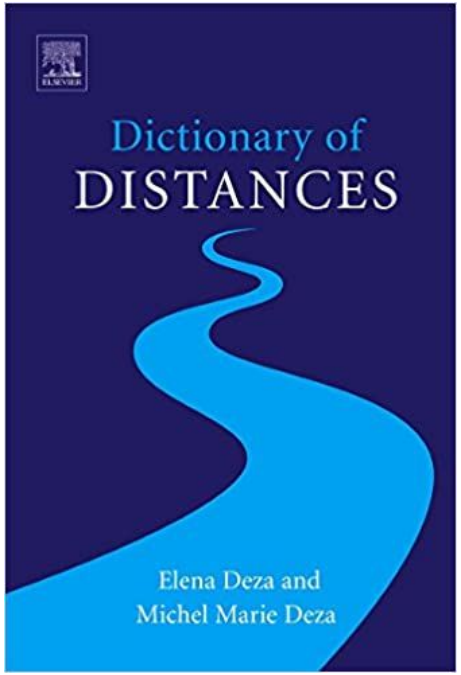

Distância Euclidiana

A **medida** de distância **euclidiana** é utilizada para definir o quão **semelhantes** os exemplos são a partir de **coordenadas cartesianas** e presumindo uma **reta** entre os pontos.

X: feature 1
Y: feature 2
Z: feature 3

$$2\text{D}: \sqrt{(x_1 - x_0)^2 + (y_1 - y_0)^2}$$

$$3\text{D}: \sqrt{(x_1 - x_0)^2 + (y_1 - y_0)^2 + (z_1 - z_0)^2}$$

$$4\text{D}: \sqrt{(x_1 - x_0)^2 + (y_1 - y_0)^2 + (z_1 - z_0)^2 + (a_1 - a_0)^2}$$

$$n\text{D}: \sqrt{(x_1 - x_0)^2 + (y_1 - y_0)^2 + (z_1 - z_0)^2 + (a_1 - a_0)^2 + \cdots}$$

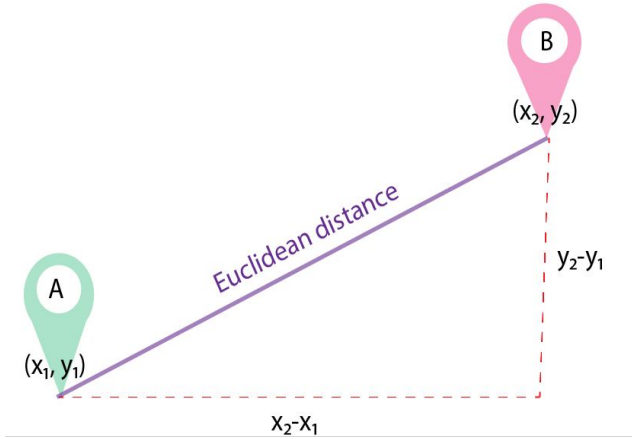

Distância dos Cossenos

Nesta distância calculamos a distância angular (cos (theta)) entre os objetos a partir de suas coordenadas

$$
\begin{aligned}
&\textit{Cosine Distance} \\
&\quad = 1 - \textit{Cosine Similarity} \\
&\quad = 1 - \cos(\theta) \\
&\quad = 1 - \frac{\boldsymbol{p} \cdot \boldsymbol{q}}{\|\boldsymbol{p}\|_2 \|\boldsymbol{q}\|_2} \\
&\quad = 1 - \frac{\sum_{i=1}^{n} p_i q_i}{\sqrt{\sum_{i=1}^{n} p_i^2} \sqrt{\sum_{i=1}^{n} q_i^2}}
\end{aligned}
$$

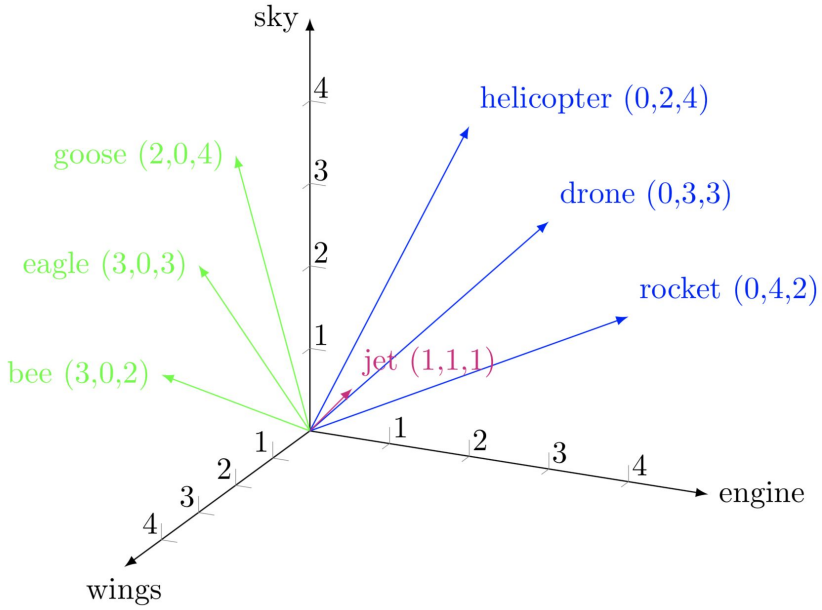

Distância de Hamming vs Levenshtein

- A distância de Hamming calcula a diferença absoluta entre sentenças (textos ou hashes)
- Para um medida de distância mais flexível utilizamos a métrica de levenshtein, na qual calcula o número de modificações necessárias para igualar os textos

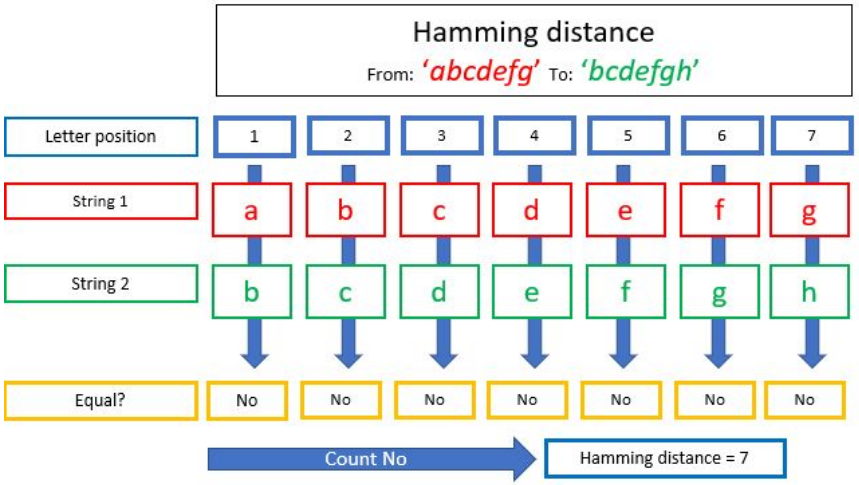

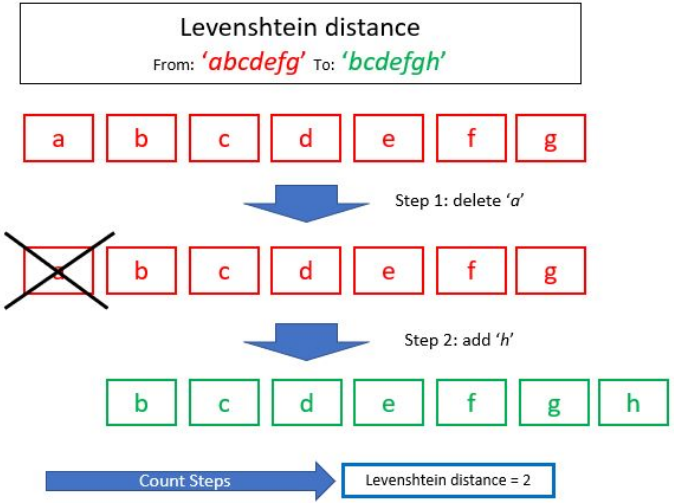

Desafios

- Após aplicarmos uma medida de distância para todos os exemplos buscamos encontrar a formação natural de grupos (imagem da esquerda).
- No entanto, quando lidamos com um dataset de alta dimensionalidade pode ocorrer de não haver uma separação clara entre os grupos (imagem da direita).

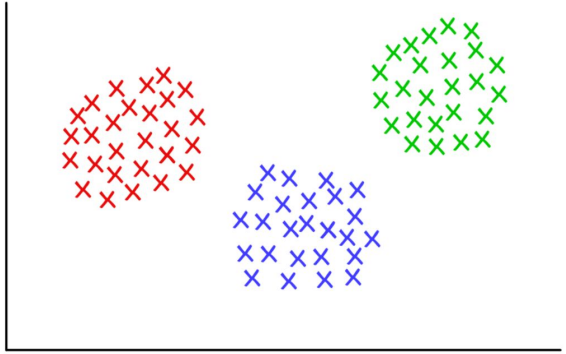

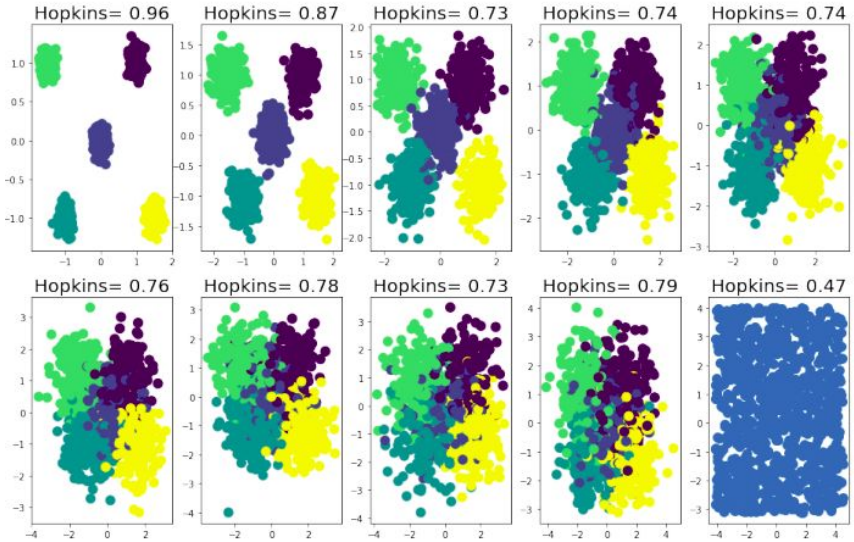

Desafios

- Além da dificuldade na visualização dos grupos, a alta dimensionalidade aumenta a dispersão dos dados e com isso prejudica a performance dos algoritmos
- Outro problema é o custo de armazenamento de uma quantidade excessiva de informação (exemplo, tensores)

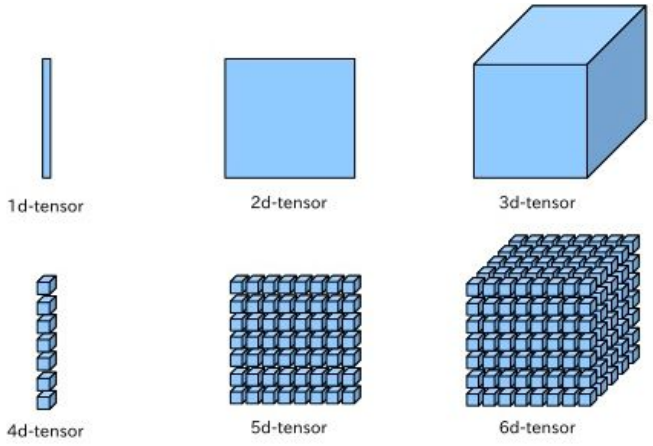

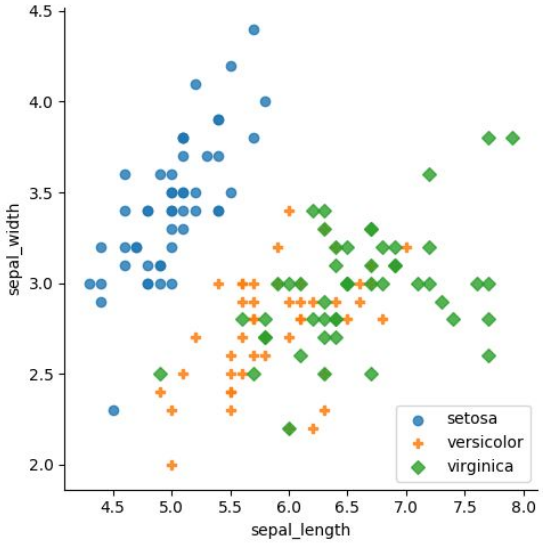

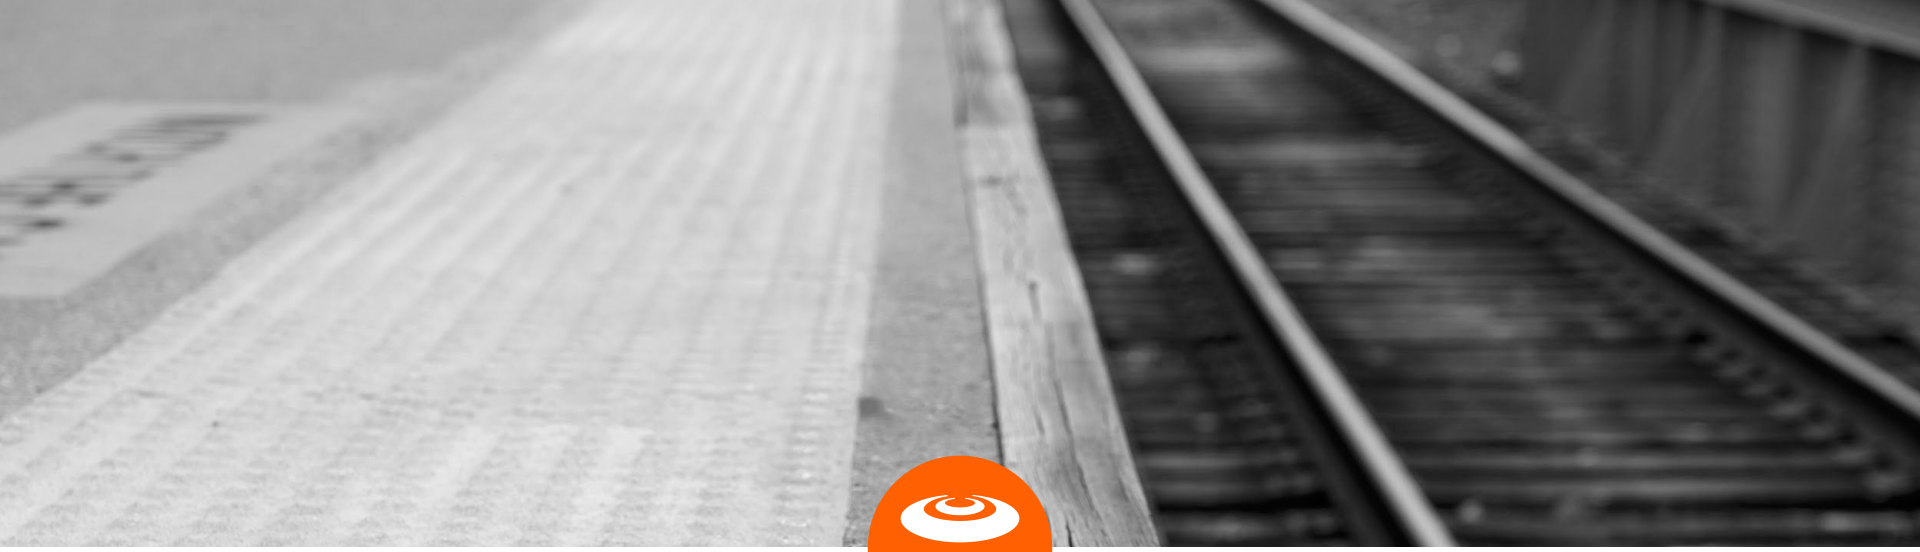

Hands On!

Experimentos em Machine Learning com Python

Hands On 1

Nesta atividade iremos utilizar uma fonte de dados baseada em imagens;

- Iremos transformar esses dados brutos em um dataset
  - considere a escala de cinza para ter uma representação 2d (utilize a lib cv2 para isso)
- Em seguida iremos definir a medida de distância euclidiana e calcularemos a matriz de distâncias
  - utilize o pairwise_distance do sklearn
- Iremos visualizar a matriz e discutiremos os clusters formados

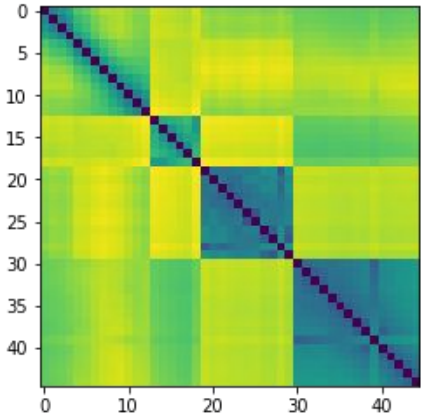

Hands On 2

Amazon Alexa Reviews

A list of 3150 Amazon customers reviews for Alexa Echo, Firestick, Echo Dot etc.

- Suponha que a Amazon lhe contrate para tentar identificar segmentos (clusters) das opiniões dos clientes acerca da Alexa. No entanto a equipe de data science da Amazon ao gerar uma matriz de similaridade não encontrou padrões relevantes (primeira imagem)
- Você precisará corrigir o script da equipe da Amazon a fim de gerar a matriz de similaridade correta (segunda imagem)
- Dica: você precisará fazer uma pequena alteração
  - mudar o valor de um parâmetro
  - escrever uma linha de código

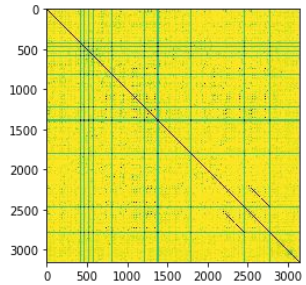

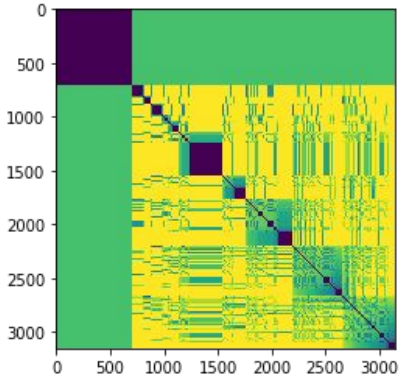

C . e . S . A . R

Pessoas impulsionando inovação.

Inovação impulsionando negócios.

NOSSO CONTATO

mso@cesar.org.br
mso2@cesar.school