INTELIGÊNCIA ARTIFICIAL

Aprendizado Descritivo
Clustering

Marcos de Souza
mso2@cesar.school

C.E.S.A.R school

Transformações dos Dados

Transformações

- Quando os dados estão em escalas diferentes é comum **normalizarmos** para converter em uma mesma escala (exemplo: valores entre 0 e 1)
- Essa **normalização** diminuirá o **impacto** no cálculo de distância entre os objetos
- Os dados em escalas distintas geralmente são bem dispersos quando aplicamos uma medida simples de distância

	Pclass	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked
0	3	1	22.0	1	0	523	7.2500	2
1	1	0	38.0	1	0	596	71.2833	0
2	3	0	26.0	0	0	669	7.9250	2
3	1	0	35.0	1	0	49	53.1000	2
4	3	1	35.0	0	0	472	8.0500	2
...	...	...	...	...	...	...	...	...
886	2	1	27.0	0	0	101	13.0000	2
887	1	0	19.0	0	0	14	30.0000	2
888	3	0	24.0	1	2	675	23.4500	2
889	1	1	26.0	0	0	8	30.0000	0
890	3	1	32.0	0	0	466	7.7500	1

891 rows × 8 columns

	0	1	2	3	4	5	6	7
0	1.0	1.0	0.271174	0.125	0.000000	0.769118	0.014151	1.0
1	0.0	0.0	0.472229	0.125	0.000000	0.876471	0.139136	0.0
2	1.0	0.0	0.321438	0.000	0.000000	0.983824	0.015469	1.0
3	0.0	0.0	0.434531	0.125	0.000000	0.072059	0.103644	1.0
4	1.0	1.0	0.434531	0.000	0.000000	0.694118	0.015713	1.0
...	...	...	...	...	...	...	...	...
886	0.5	1.0	0.334004	0.000	0.000000	0.148529	0.025374	1.0
887	0.0	0.0	0.233476	0.000	0.000000	0.020588	0.058556	1.0
888	1.0	0.0	0.296306	0.125	0.333333	0.992647	0.045771	1.0
889	0.0	1.0	0.321438	0.000	0.000000	0.011765	0.058556	0.0
890	1.0	1.0	0.396833	0.000	0.000000	0.685294	0.015127	0.5

891 rows × 8 columns

Scaler em Python

Code use example

```
# importa o pacote cluster
from sklearn.preprocessing import MinMaxScaler, StandardScaler

scaler = MinMaxScaler() # StandardScaler()

# Aplica a normalização
X_new = scaler().fit_transform(X)
```

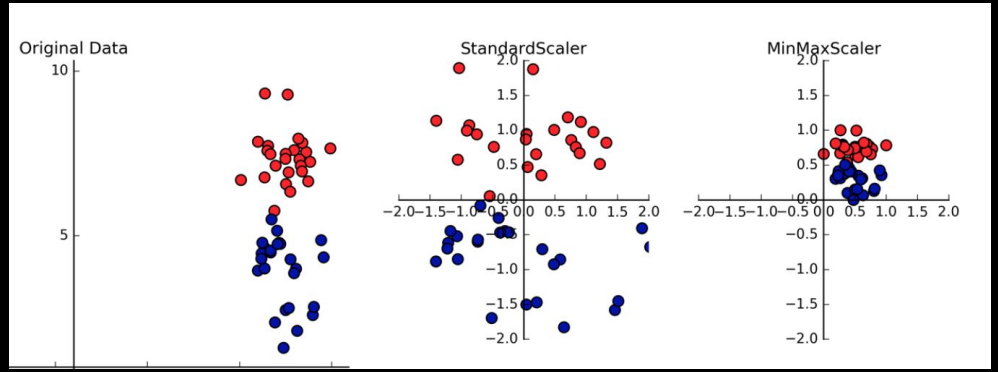

1

Análise de Componentes Principais (PCA)

Redução da Dimensionalidade

Uma visão **resumida** das técnicas de redução de dimensionalidade

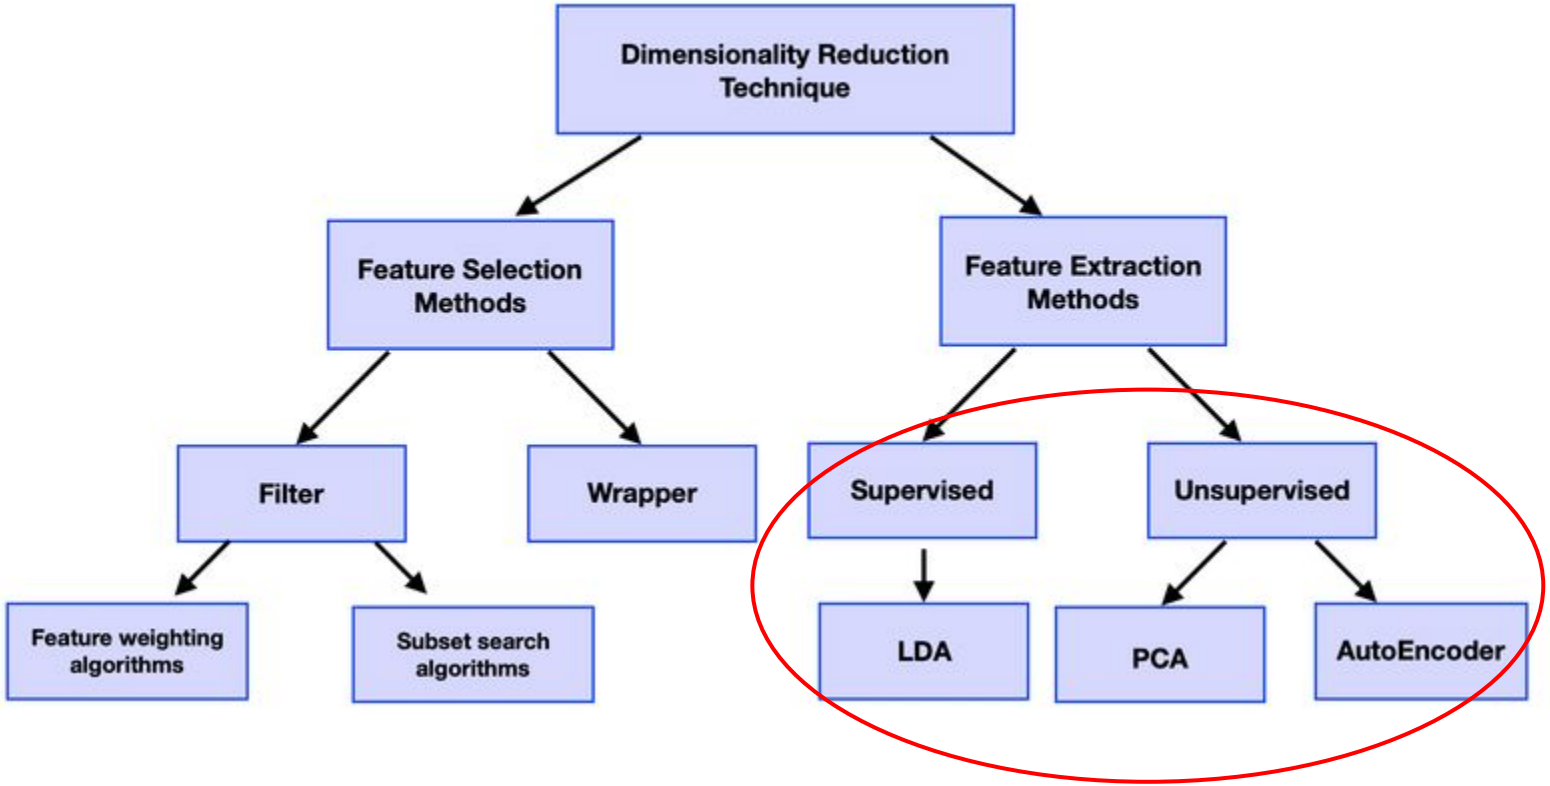

PCA

- Trata-se de uma técnica não-supervisionada de transformação que visa **linearizar** a direção dos dados
- Possui uma versão não-linear onde é preciso informar uma função de kernel (inclusive linear) que irá convergir com os dados

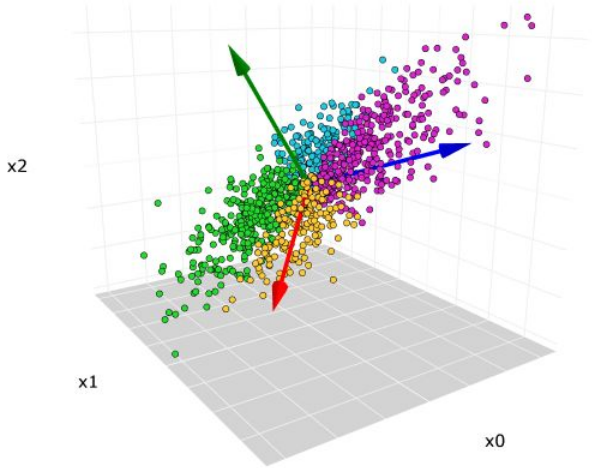

PCA step-by-step

- passo 1: calcula a matriz de **covariância**
- passo 2: extrai os **autovetores** a partir dessa matriz
- passo 3: **seleciona** os autovetores mais explicativos

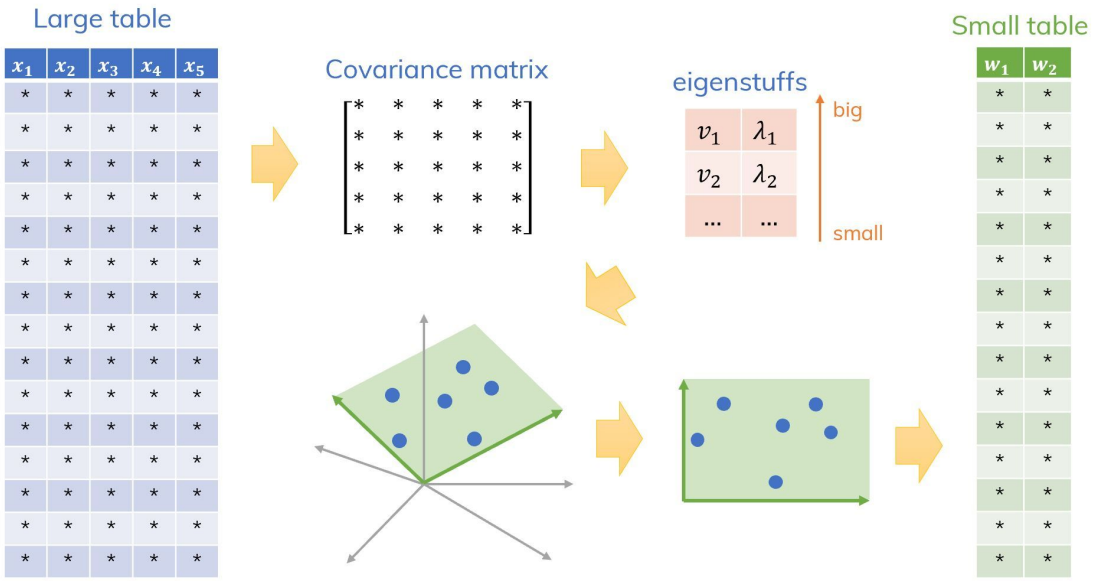

mas antes ...

Análise de Clustering (poucas features)

- Análise feature a feature em busca do melhor agrupamento

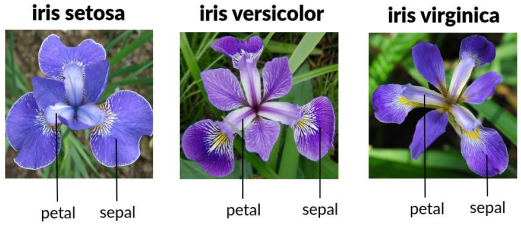

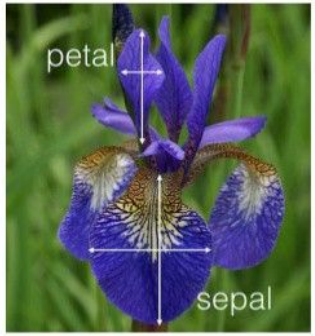

Training / test data

Features				Labels
Sepal length	Sepal width	Petal length	Petal width	Species
5.1	3.5	1.4	0.2	Iris setosa
4.9	3.0	1.4	0.2	Iris setosa
7.0	3.2	4.7	1.4	Iris versicolor
6.4	3.2	4.5	1.5	Iris versicolor
6.3	3.3	6.0	2.5	Iris virginica
5.8	3.3	6.0	2.5	Iris virginica

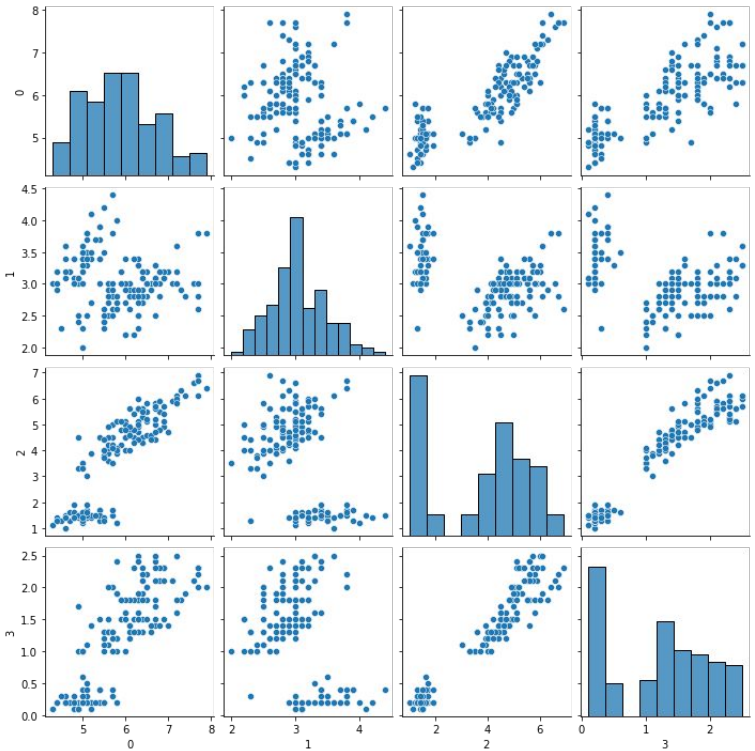

Matriz de Covariância

Matriz de Covariância

Ao calcularmos a matriz de covariância encontramos a direção dos dados

$$\mathrm{Cov}\,(X, Y) = \frac{\sum(X_i - \overline{X})(Y_j - \overline{Y})}{n}$$

$$\begin{bmatrix} \mathrm{Var}(x_1) & \cdots\cdots & \mathrm{Cov}(x_n, x_1) \\ \vdots & \ddots & \vdots \\ \mathrm{Cov}(x_n, x_1) & \cdots\cdots & \mathrm{Var}(x_n) \end{bmatrix}$$

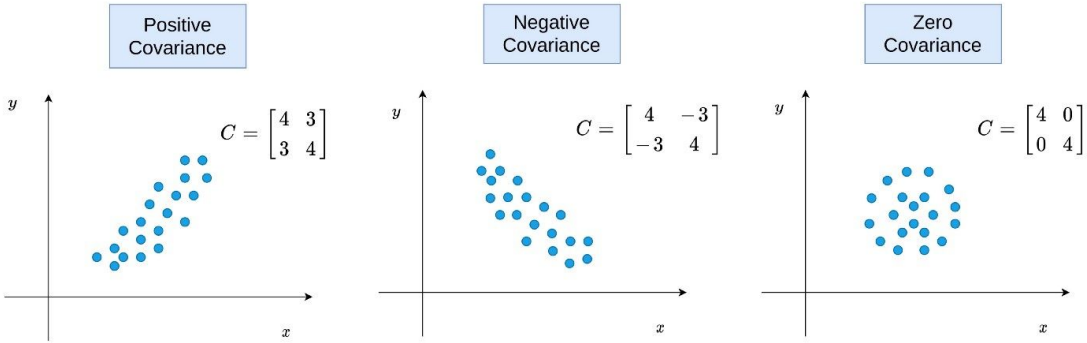

Autovetores da Matriz de Covariância

- Ao calcularmos a matriz de covariância encontramos a direção dos dados
- Quando calculamos os autovetores achatamos (**linearizamos**) a dispersão dos dados

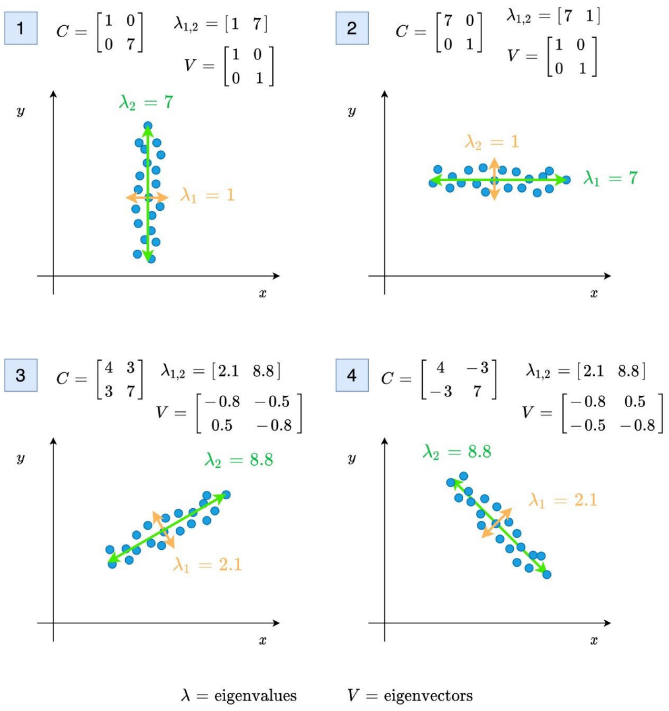

Ref:
https://towardsdatascience.com/5-things-you-should-know-about-covariance-26b12a0516f1

Selecionando os Componentes Principais

- Plotamos os pontos em todas as dimensões e selecionamos os autovetores (componentes) que tenham maior cobertura sobre a variabilidade dos dados (variância)

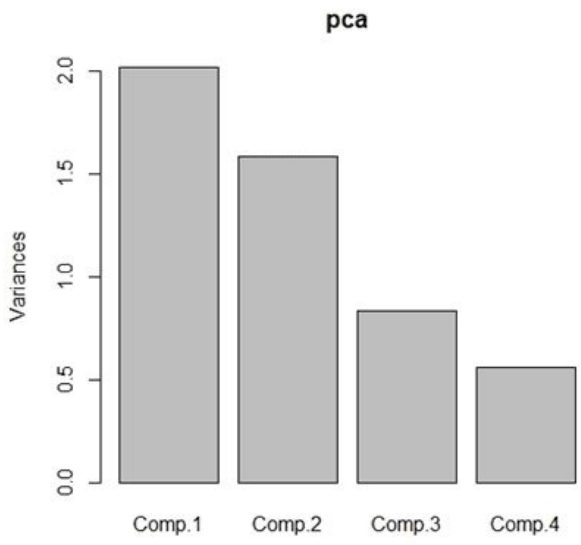

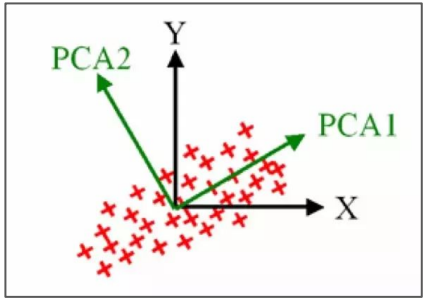

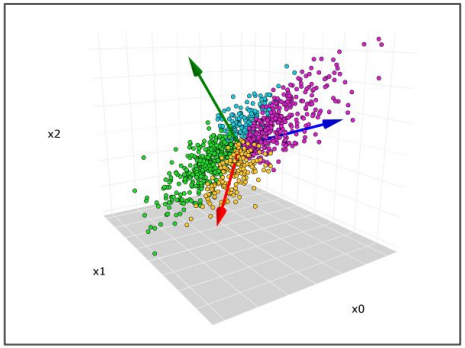

Limitações

- Em estruturas complexas não lineares o PCA obterá baixo desempenho na detecção dos clusters/classes.
- Neste ponto é importante selecionarmos um kernel apropriado

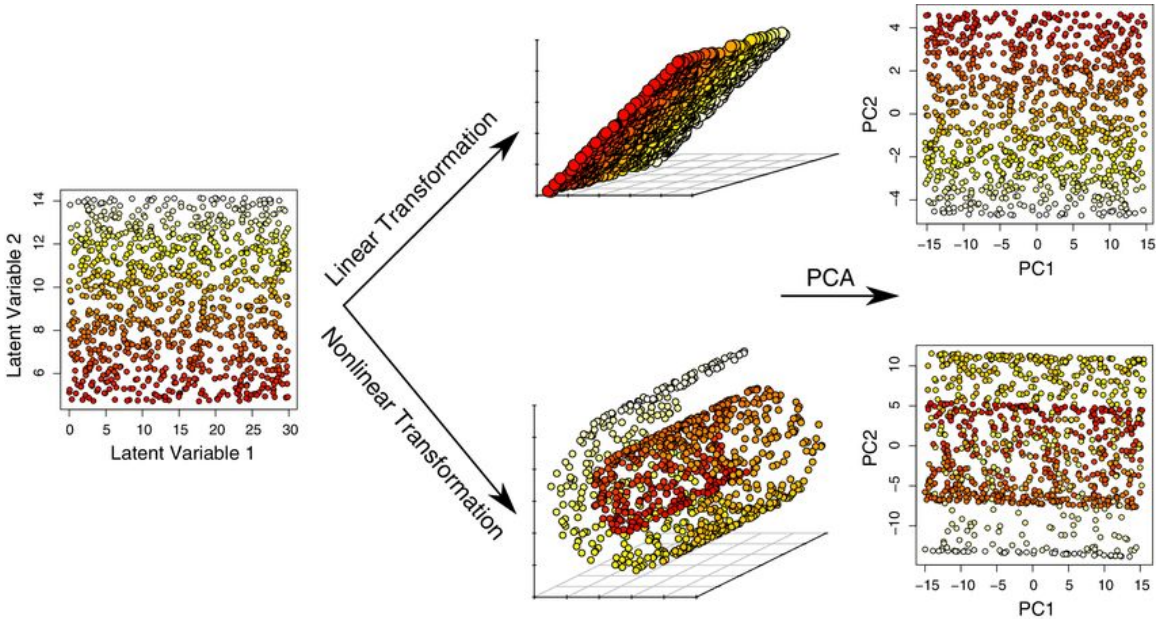

1

Análise de Discriminante Linear (LDA)

Selecionando os Componentes Principais

Trata-se de um método supervisionado de geração de componentes lineares que consigam maximizar a separabilidade dos dados

PCA:
component axes that maximize the variance

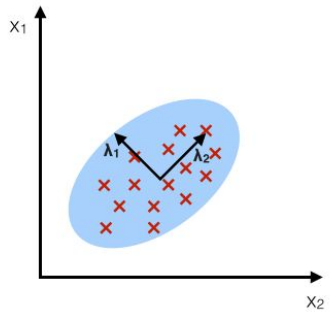

LDA:
maximizing the component axes for class-separation

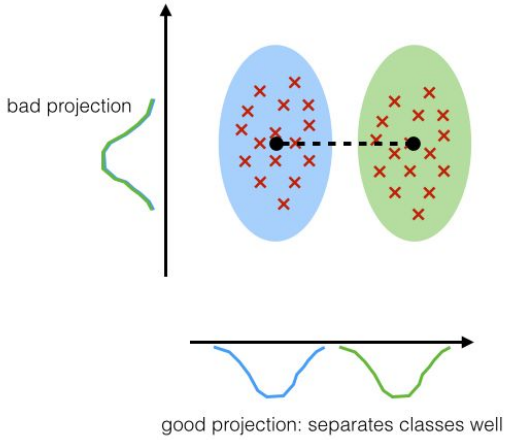

Análise de Discriminante Linear

Diferente do PCA, o número de componentes no LDA será o número de labes -1

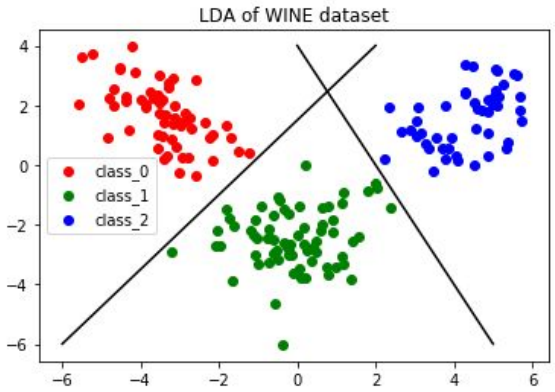

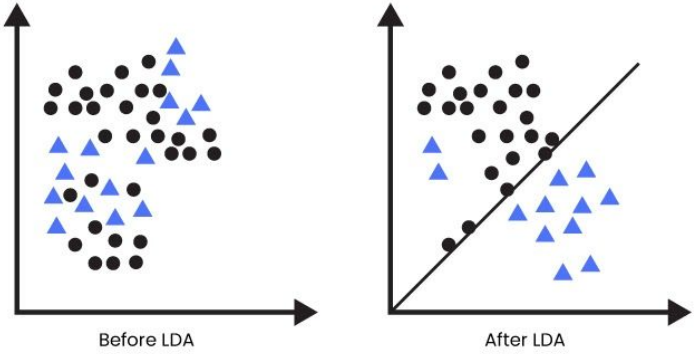

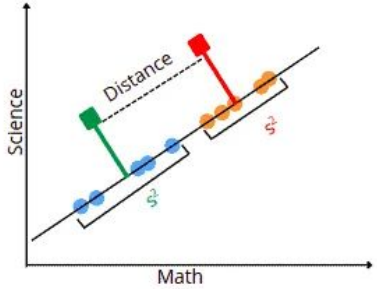

$$\frac{(\text{mean1} - \text{mean2})^2}{s^2 + s^2}$$

Análise de Discriminante Linear

Limitações: o LDA presume que os dados pertencem a uma distribuição gaussiana

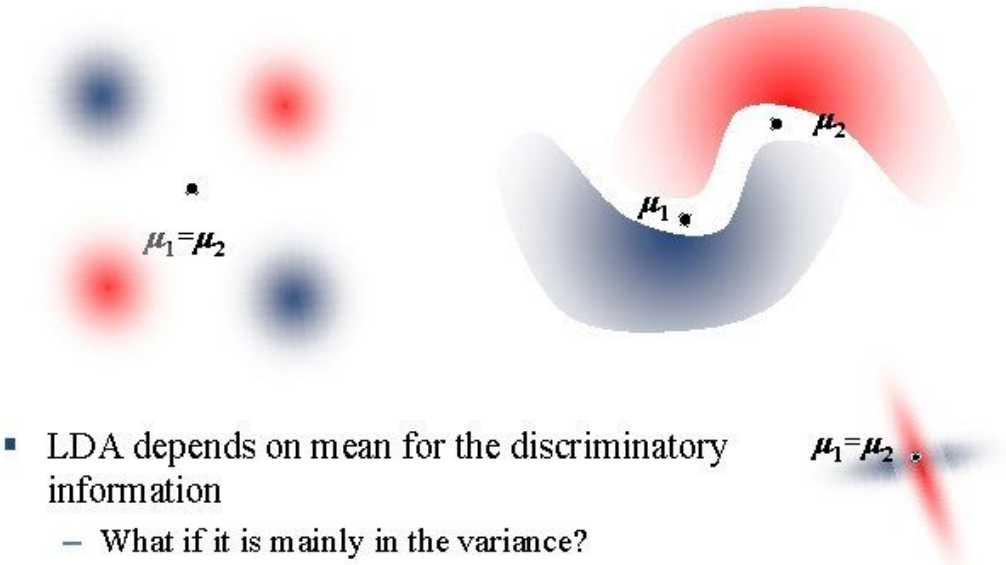

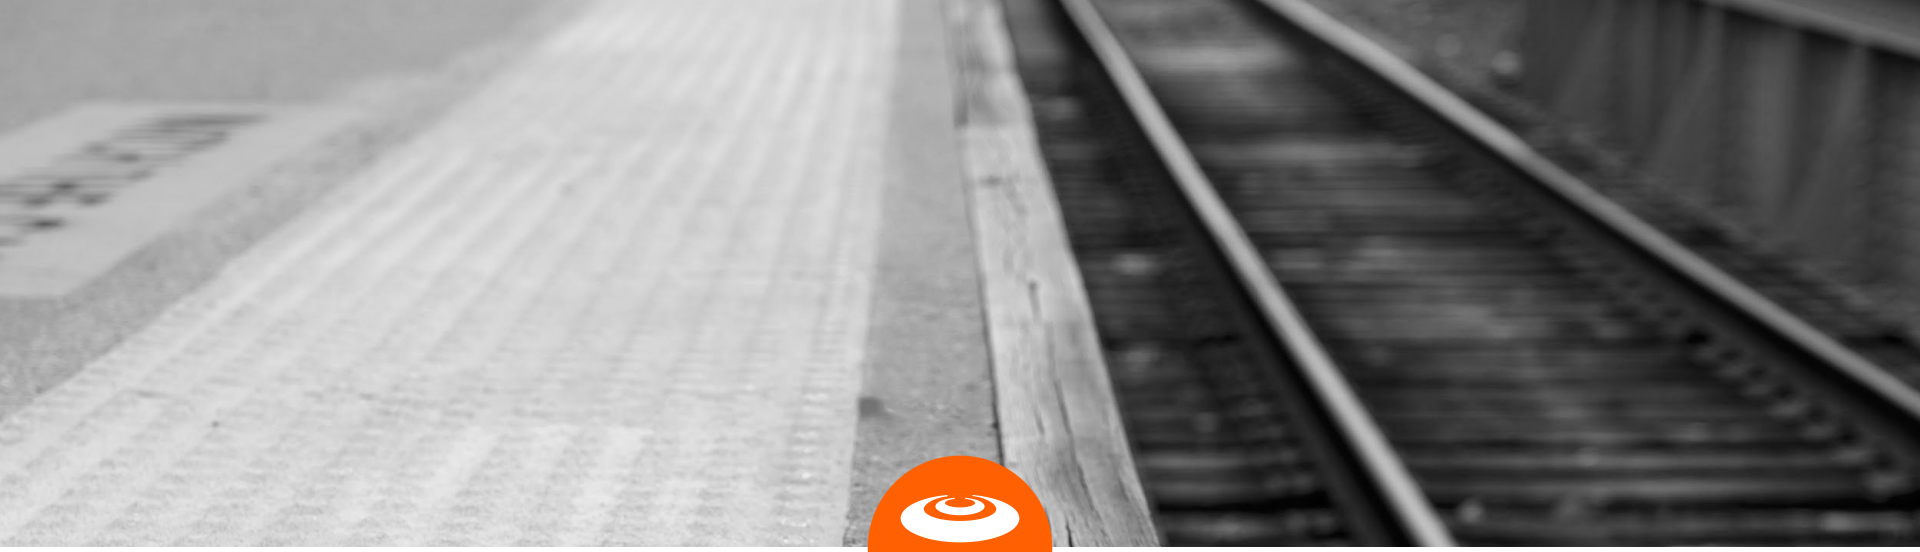

Hands On!

Experimentos em Machine Learning com Python

C . e . S . A . R

Pessoas impulsionando inovação.

Inovação impulsionando negócios.

NOSSO CONTATO

mso@cesar.org.br
mso2@cesar.school